1 标题：利用 PagedAttention 实现大语言模型服务的高效内存管理
解决主要问题：KV 缓存内存大量浪费的问题，提高吞吐量 2-4 倍。
问题核心：KV 缓存存储在连续的内存空间里，其生命周期和长度无法预先确定，可能会导致严重的内部碎片化和外部碎片化，导致内存空间大量浪费。
解决方法：
分页注意力（PagedAttention）将请求的 KV 缓存划分为多块，每个块大小相同，按需分配他们。消除了外部碎片化问题，还能实现请求间共享显存。

2 标题：SGLang：高效执行结构化语言模型程序
解决主要问题：（1）用于表达和执行的语言模型程序的系统效率低下的问题，源于冗余计算和内存使用。（2）编写语言模型程序繁琐而困难，可读性低的问题。
问题核心：系统缺乏有效机制促进 KV 缓存的重用，导致不必要的计算和内存浪费。
解决方法：
SGLang 系统利用 LM 程序中的多调用结构以实现高效执行。包含两个部分：前端语言和后端运行时。前端简化 LM 程序的编程，运行时则加速了其执行。
SGLang 加速的优化方法：（1）RadixAttention：通过基数树管理 KV 缓存实现高效匹配、插入和淘汰，促进 KV 缓存的重用。（2）压缩有限状态机：为结构化输出实现更快的解码。
SGLang 提升了吞吐量。